



博士学位论文答辩



基于多智能体强化学习的主动配电网 异质性协同分布式控制方法研究



学位申请人：郑晓东
指导教师：曹晖 教授
学科名称：电气工程



2026年2月

01绪论

—
研究背景与意义
双碳目标下的
新型电力系统挑战

02 异质设备协同下分 布式无功电压控制

—
SHOM方法

03 异质动作空间下 的负荷频率支撑控制

—
OHASAC方法

04异质资源协同下的 主动配电网充电负荷 调度

VS-MATRPO方法

— 05大语言模型增强 的强化学习框架

LLM-MARL框架

— 06结论与展望

汇报提纲 CONTENTS

01

第一章：绪论

1.1 研究背景与意义

双碳目标下的新型电力系统挑战

⚡ 宏观背景

"双碳"目标下，配电网面临**新能源高渗透、高不确定性、低惯量**的运行新格局。

⚙️ 主动配电网的角色转变

配电网不再只是输配通道，而是实现**源网荷储协同**的核心控制层。

⚠️ 核心挑战

系统呈现**低惯量、异质性与分布式控制**并存，传统方法难以应对。



图1.1 主动配电网智能控制的核心挑战与异质性特征

1.2 核心挑战分析

四类核心挑战及其异质性特征

1 异质设备协同下的无功电压控制

设备异质性:

- 调压器: 有限档位离散动作
- 电容器组: 投切二值动作
- 储能系统: 连续功率动作

调压器:



电容器组:



储能系统:



2 异质动作空间下的负荷频率控制

动作空间异质性:

- 分布式光伏: 离散档位调节
- 储能系统: 连续有功功率调节
- 柔性负荷: 二值响应 (投切)


分布式光伏:



储能系统:




柔性负荷



3 异质资源协同下的充电负荷调度

资源异质性:


- 空间分布: 城区/郊区/中心站点
- 容量配置: 十桩级到百桩级不等
- 储能资源: 容量差异显著



4 数据驱动方法的开发与部署瓶颈

方法论层面的异质性:

- 环境建模方式差异
- 奖励函数设计逻辑各异
- 约束处理机制本质差异



第一章 绪论：主动配电网异质性协同控制的研究现状、挑战与创新

章节主线 | 设备异质性 → 动作空间异质性 → 资源异质性 → 方法异质性

第二章

异质设备协同

电压/无功协调控制

SHOM算法

- ▶ 灵敏度排序机制
- ▶ 电压-无功协同优化
- ▶ CTDE框架特征融合

第三章

异质动作空间

负荷频率协调控制

OHASAC算法

- ▶ 序贯更新策略
- ▶ 混合动作空间处理
- ▶ 异质策略自适应

第四章

异质资源协同

EV充电协调优化

VS-MATRPO算法

- ▶ 虚拟共享储能
- ▶ 多主体信赖域优化
- ▶ 充电站-储能-电网

第五章

大模型增强

智能仿真与规划

APG框架

- ▶ 自主规划生成
- ▶ 自然语言→仿真代码
- ▶ PowerZoo平台

第六章 总结与展望：研究成果总结、创新点归纳与未来展望

主动配电网中基于异质多智能体强化学习的协同控制方法研究

研究对象间的递进关系

2

SHOM方法
第二章

主动配电网内部无功电压调控

3

OHASAC方法
第三章

主动配电网对于主网的支撑

4

VS-MATRPO方法
第四章

配电网内部负荷侧调控

5

LLM-MARL框架
第五章

统一训练方法和环境

章节
分布与
联系

第二章
分布式无功电压控制
基于异质性设备
配网电压调控

网内-网间
电压-频率

第三章
负荷频率协同控制
基于异质性动作主网频率支撑

网间-站间
频率-负荷

第四章
波动负荷智能调度
基于异质性资源
站端负荷调控

现实-数据
数据-框架

第五章
大模型增强智能仿真
基于大模型自动环境
构建

仿真环境支撑

数据集支撑

自动化支撑

第五章：PowerZoo 电网环境训练平台

02

第二章：异质设备协同下的 分布式无功电压控制

2.1 问题是什么

异质设备协同的无功电压控制问题



调压器 (OLTC)

动作类型: 离散档位

响应时标: 分钟级

主要约束: 日动作次数限制



电容器组 (CB)

动作类型: 二值投切

响应时标: 分钟至小时级

主要约束: 投切寿命约束



储能系统 (ESS)

动作类型: 连续功率

响应时标: 秒级

主要约束: 能量边界与功率斜率

核心难点

① 混合离散-连续特性

离散动作（调压器、电容器）与连续动作（储能）需在统一框架下协调优化

② 非线性耦合

各设备动作通过潮流方程产生非线性耦合，单一设备的控制决策会影响全网电压分布

③ 多重约束

需满足电压安全边界、设备动作次数限制、储能SOC约束等多重约束

优化目标: 在满足设备约束的前提下，最小化电压越限次数、控制误差和网络功率损耗的综合效应。

2.1 直观的物理建模

异质设备协同的无功电压控制问题 (Volt-Var Control)

辐射型配电网支路潮流模型




图2.1 辐射型配电网支路潮流模型

支路潮流模型 (Branch Flow Model)

有功平衡: $P_j = \sum_{e_{jk}} P_{e_{jk}} - P_{e_{ij}} + R_{e_{ij}} \ell_{e_{ij}}$

无功平衡: $Q_j = \sum_{e_{jk}} Q_{e_{jk}} - Q_{e_{ij}} + X_{e_{ij}} \ell_{e_{ij}}$

电压降落: $v_j^2 = v_i^2 - 2(RP_{e_{ij}} + XQ_{e_{ij}})$

优化目标函数

$$\mathcal{L} = \sum_{i=1}^N (f_{vv}(x_i) + f_{ce}(x_i) + f_{pl}(x_i))$$

- f_{vv} : 电压越限惩罚 (最高优先级)
- f_{ce} : 控制设备动作代价
- f_{pl} : 网络有功损耗

如何通过分布式控制对主动配电网中的**异质设备**进行协同优化控制?

2.2 为什么难

现有方法的局限性

× 传统集中式优化方法

局限性

- 计算复杂度高，实时控制需求负担大
- 通信负担重，需要完备的全局信息
- 依赖精确网络参数与实时量测

不适用原因

配电网中负荷波动、临时拓扑变化和传感器部署有限等因素使得完全可观测的假设难以满足，且计算复杂度随设备规模超线性增长。

由 现有多智能体强化学习方法

核心假设

现有MARL方法（如MADDPG、MAPPO、QMIX）普遍假设**智能体同质性**，通过**参数共享**技术让智能体共享动作空间和策略网络。

关键问题

- **策略更新冲突**：不同时间尺度设备互相影响动作策略分布
- **训练不稳定**：异质设备加剧多智能体训练的非平稳性
- **信用分配难题**：难以评估各设备对全局性能的贡献

研究动机：迫切需要发展一种能够有效处理异质设备协同的多智能体强化学习方法，建立异质设备物理约束与智能体策略空间的映射机制。

2.3 怎么解决

CTDE框架与马尔可夫博弈建模

集中训练-分散执行 (CTDE) 框架

CTDE框架在**训练阶段**采用集中式信息融合训练，通过全局状态训练**中心评价网络**；在**推理阶段**各智能体仅依赖局部观测与本地策略进行独立决策。

极大缓解多智能体环境中的非平稳性问题

训练

实现分布式、自主化的控制过程



推理

部分可观测马尔可夫博弈建模

将异质设备协同控制问题形式化为八元组：

$$\mathcal{G} = (\mathcal{N}_a, \mathcal{S}, \{\mathcal{A}_i\}_{i \in \mathcal{N}_a}, \{\mathcal{O}_i\}_{i \in \mathcal{N}_a}, \mathcal{T}, r, \gamma, T)$$

马尔可夫博弈



马尔可夫链




图2.2 集中式训练、分布式执行 (CTDE) 架构

2.3 怎么解决

本文的控制结构

动作空间/状态空间

建模电容/储能/以及调压器抽头的控制动作及系统状态

联合动作空间

$$\begin{aligned} a^C &\in \{0, 1\}, \\ a^R &\in \{1, 2, \dots, N_{\text{tap}}\}, \\ a_d^B &\in \{0, 1\}^{N_{\text{bat}}}, \\ \mathcal{A}_i &= a^{C_i} \times a^{R_i} \times a_d^{B_i}, \\ \mathcal{A} &= \prod_{i=1}^{N_a} \mathcal{A}_i. \end{aligned}$$

联合状态空间

$$\begin{aligned} s &= (s_v, s_f), \\ s_v &= \text{Concat}(s_v^i), \quad \forall i \in \mathcal{N}, \\ s_f &= \text{Concat}(s_{\text{tap}}^{\mathcal{R}_i}, s_{\text{stat}}^{\mathcal{C}_i}, s_{\text{soc}}^{\mathcal{B}_i}, s_{\text{dp}}^{\mathcal{B}_i}) \end{aligned}$$

根据奖励函数迭代训练，优化得到目标函数稳定值

$$\begin{aligned} r(s_t, a_t) = - & \left(\sum_{i \in \mathcal{N}} (f_{vv}(s_t^i, a_t) + f_{pl}(s_t^i, a_t)) \right. \\ & + \sum_{ij \in \mathcal{N}_a} f_{ce}(s_t^i, a_t^j) + \sum_{ij \in \mathcal{N}_a} f_{dcp}(s_t^i) \\ & \left. + \sum_{B_i \in \mathcal{N}_{\text{bat}}} f_{deg}^B(s_t^{B_i}, a_t^{B_i}) \right) \end{aligned}$$

最终目标是获取最优策略

$$\pi^* = \arg \max_{\pi} \mathcal{J}(\pi)$$

$$\mathcal{J}(\pi) = \mathbb{E}_{s_0: \infty \sim \rho_{\pi}^{0: \infty}, a_0: \infty \sim \pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$




图2.3 本文使用的CTDE架构

2.3 怎么解决

单调性理论与多智能体优势函数分解

多智能体训练非平稳性问题

多智能体并发学习**导致环境非平稳**，如果每个智能体仅基于自身视角计算优势函数（Advantage Function）并更新策略，**极易因为其他智能体的探索而抵消自身的改进**，导致联合策略无法单调收敛。

多智能体优势函数分解定理

多智能体马尔可夫博弈框架下，全局优势函数可按序分解：

$$A^\pi(s, a) = \sum_{m=1}^N A_{i_m}^\pi(s, a_{i_1}, \dots, a_{i_{m-1}}, a_{i_m})$$

单智能体单调改进理论

基于TRPO理论，策略性能与代理函数之间存在下界关系：

$$\mathcal{J}(\pi') \geq \mathcal{J}(\pi) + \mathbb{E}_{s \sim \rho_\pi, a \sim \pi'} [A_\pi(s, a)] - \frac{2\gamma\epsilon_{\max}}{(1-\gamma)^2} \text{KL}_{\max}(\pi, \pi')$$

只要控制KL散度在适当范围内即可保证单调改进。

顺序更新机制

第 i_m 个体的代理目标函数：

$$L_{k^{i_m}}(\theta) = \mathbb{E} \left[\min \left(r \cdot \hat{M}, \text{clip}(r) \cdot \hat{M} \right) \right]$$

定理（单调异质更新）：若各智能体按顺序更新规则在给定的信赖域罚项下顺序更新，则联合策略序列满足全局性能关于迭代步单调不降。

2.3 怎么解决

基于V-Q灵敏度的动态排序机制

电压-无功灵敏度计算


基于潮流方程的雅可比矩阵，V-Q灵敏度矩阵为：

$$S_{VQ} = \frac{\partial V}{\partial Q} = (J_{QV} - J_{Q\theta} J_{P\theta}^{-1} J_{PV})^{-1}$$

时序加权排序

累积灵敏度指标	$S_{VQ}^{cum}(i) = \sum_{b=1}^n S_{VQ}(b, i) $
时序权重	$w_t = \frac{r_t}{r_T} = \frac{r(s_t, a_t)}{\sum_{\tau=1}^T r(s_\tau, a_\tau)}$
加权累积灵敏度	$S_{VQ}^w(i) = \sum_{b \in B_{vio}} w_b \cdot S_{VQ}(b, i) \cdot \Delta V_b $

灵敏度计算流程



配电网灵敏度可视化





图2.4 V-Q 灵敏度计算流程与配电网节点灵敏度可视化

2.3 怎么解决

SHOM算法流程



核心创新点

- ★ 基于物理灵敏度的动态排序机制
利用电力系统物理特性优化更新策略
- ★ 序贯更新避免策略冲突
后更新智能体利用前序智能体的最新策略

算法优势

- 收敛速度快 (小模型约5000步内收敛)
- 最终性能优异
- 训练稳定性强
- 适用于异质动作空间
- 具有单调改进理论保证

2.4 效果如何

实验设置

实验平台

硬件环境： 配备A800 GPU的服务器

软件框架： PyTorch + OpenDSSDirect + CuPy GPU加速

仿真平台： PowerZoo多智能体强化学习环境

IEEE节点测试系统

IEEE 13节点系统


小规模配电网，用于算法验证

IEEE 34节点系统


中等规模配电网，用于详细分析

IEEE 123节点系统


大规模配电网，用于可扩展性验证






(a) 13 节点拓扑图



(b) 34 节点拓扑图




(c) 123 节点拓扑图




2.4 效果如何


训练收敛性分析



(a) 13BUS 网络训练收敛曲线对比



(b) 34BUS 网络训练收敛曲线对比



(c) 123BUS 网络训练收敛曲线对比

对比算法

PPO (单智能体)

SAC (单智能体)


QMIX (多智能体)

HAPPO (多智能体)


关键发现： SHOM算法在三个测试网络上均表现出显著优势：①**收敛速度最快**——约5000步内即可实现收敛；②**最终收敛奖励值最高**——明显优于PPO、SAC、Qmix和HAPPO等方法；③**训练曲线整体波动最小**——表现出良好的稳定性与一致性。

2.4 效果如何


多维性能对比



(a) 13BUS 网络雷达图



(c) 34BUS 网络雷达图



(e) 123BUS 网络雷达图

关键支路网络损耗对比

线路	HAPPO	PPO	SHOM
Line.L14	5.76	11.96	2.70
Line.L27	9.82	20.53	4.32
Line.L32	6.14	12.25	1.19
平均值	1.44	2.66	0.72

单位：kW

性能提升总结

- ✓ 平均网损降低50%
相比次优算法HAPPO
- ✓ 电压越限率降低50%
从平均8.3%降至4.1%
- ✓ 调压器动作次数降低36.6%
从12.3次/天降至7.8次/天
- ✓ 电压合格率维持98.5%以上
- ✓ 高光伏渗透率场景下

2.4 效果如何

可扩展性与鲁棒性验证

控制动作分析


SHOM算法在含噪声环境下体现出**最快的收敛速度、最低的平均网损率、最少的控制动作次数以及较高的储能利用率。**

实际部署能力


使用连续24小时实际运行数据的部署实验表明，SHOM算法在多种情况下均保持**稳定和高效**的性能，进一步凸显了其在实际部署中的优势。

可扩展性结论

随着网络规模逐渐扩大，SHOM算法始终保持**最小的性能衰减幅度**，表现出最强的可扩展性。尤其在大规模的123BUS网络中，其优势进一步放大。




(a) 含噪声训练阶段的网损功率（单位：千瓦）




(b) 24 小时部署阶段的网损功率（单位：千瓦）

图 2.4 噪音训练及部署性能对比



(a) 综合奖励



(d) 34 节点网络中电池的平均放电动作次数

图 2.4 SHOM可拓展性分析及储能利用

2.4 效果如何

单节点部署验证

单节点设置


实验选取34节点网络中的BUS-890节点进行深入分析，该节点连接一个末端储能系统，使得该节点能够具有比其他节点更强的可控性和调节灵活性。

节点电压分析


选取由SHOM模型控制下的BUS-890节点在一天内的情况，可以看出，该节点一天内电压健康度平稳，电压不平衡较少出现。

线路潮流分析


在BUS-890连接的线路L32在全天范围内的功率损耗显著低于其他算法，表面SHOM算法能够有效控制储能系统满足节点需求，降低线路损耗。




(a) BUS-890 节点一天内的电压健康状况




(b) BUS-890 节点电压不平衡状态状况




(c) 电压越限情况对比 (堆叠视图)



(d) 电压越限程度对比




(a) 电池储能系统 BATT1 的有功功率输出



(b) 线路 L32 的功率损耗

本章小结

1. 本章提出基于电压-无功灵敏度排序的异质多智能体强化学习方法 SHOM，用于解决主动配电网中异质设备的分布式无功电压协同控制问题。
2. 建立含多类调节设备的配电网模型与多目标优化函数，采用 CTDE 架构实现分布式决策，并通过 V-Q 灵敏度动态排序缓解策略振荡。
3. 在多组 IEEE 标准测试系统上验证，SHOM 可显著降低网损、降低电压越限，且具备良好的协调效率、训练稳定性与可扩展性。



第三章：异质动作空间下的主动配电网负荷频率支撑控制



3.1 问题是什么

异质动作空间的负荷频率控制问题



分布式光伏 (PV)

动作类型: 离散档位调节
调节方式: 功率削减
响应时标: 秒级
约束: 受辐照度时变上限约束



储能系统 (ESS)

动作类型: 连续有功功率
调节方式: 充放电功率调节
响应时标: 毫秒级
约束: SOC安全边界约束



同步发电机 (SG)

动作类型: 离散档位/连续功率
调节方式: 功率增减指令
响应时标: 十秒级
约束: 发电速率约束(GRC)

核心难点：信用分配难题

值分解方法的局限性

集中Q函数的分解假设各智能体贡献可加性，但异质动作对全局频率恢复的边际贡献具有**非线性耦合特性**，静态分解系数难以准确捕捉这种状态依赖性。

信用分配不当的后果

局部策略梯度与全局目标方向不一致，各智能体可能陷入**相互抵消的无效调节**，导致频率控制性能下降。

优化目标: 在光伏辐照度时变、储能SOC约束等多时间尺度约束下，最小化系统频率偏差，实现多资源的协同调频。

3.2 为什么难

现有MARL方法的核心研究差距

1 多智能体信用分配问题存在

问题描述

现有值分解方法（如QMIX、QTRAN）假设价值可加性难以处理非线性信用分配问题，多智能体信用分配问题未能有效解决。

技术挑战

配电网中光伏、储能与输电网同步机的频率响应存在**多时间尺度差异**，传统值分解无法准确刻画这种跨层级耦合关系。

2 异质动作空间下的约束协同策略机制缺失

问题描述

现有方法（如MADDPG、MATD3）普遍假设**同质动作空间**，无法有效建模离散-连续混合的异质动作空间结构。

技术挑战

光伏离散档位、储能连续功率、同步机混合动作需要在**统一框架下协同优化**，参数共享机制难以适用。

3 多时间尺度约束协调不足

问题描述

现有研究往往忽略**时变光照强度**对光伏出力的影响以及**储能soc约束的跨时间尺度耦合特性**。

技术挑战

光伏毫秒级功率波动、储能秒级充放电调节与同步机十秒级响应之间的**多时间尺度约束协调**尚未得到有效处理。

3.3 怎么解决

系统建模与异质动作空间

输电网联合系统模型

同步发电机动态

摇摆方程刻画频率动态

$$2H \frac{d^2 \delta}{dt^2} = P_m - P_e - D \frac{d\delta}{dt}$$

光伏出力时变特性

辐照度影响最大可用功率

$$\bar{P}_t^{PV_i} = \eta_{inv}^i \cdot P_{STC}^{PV_i} \cdot \frac{G_t}{G_{STC}} \cdot [1 + \alpha_p (T_{cell,t} - T_{STC})]$$

储能SOC动态约束

充放电效率与容量约束

$$\frac{dSOC_t^j}{dt} = \begin{cases} -\frac{\eta_d^j P_t^{ESS_j}}{E_{cap}}, & \text{若 } P_t^{ESS_j} > 0 \text{ (放电),} \\ -\frac{P_t^{ESS_j}}{\eta_c^j E_{cap}}, & \text{若 } P_t^{ESS_j} < 0 \text{ (充电),} \\ 0, & \text{若 } P_t^{ESS_j} = 0 \text{ (待机),} \end{cases}$$

负荷频率控制优化目标

充放电效率与容量约束

$$\min_{\{u_t\}_{t=1}^T} \sum_{t=1}^T |-10\beta_f(f_t - f^{\text{ref}})|$$

最小化系统频率偏差，使频率保持在额定值（50Hz/60Hz）附近。




图3.3.1 三类智能体的异质动作空间示意图

异质动作空间特征

- **光伏:** $PV \in [0, 1]$, 连续功率限幅
- **储能:** $ESS \in [-1, 1]$, 连续充放电
- **同步机:** 离散档位或连续功率

3.3 怎么解决

异质软演员-评论家框架

集中式评论家

负责信用分配

异质策略网络

处理动作空间差异

序列选择器

优化更新顺序





图3.3.2 OHASAC 方法整体框架示意图

信用分配问题



若缺乏有效的信用分配机制，各智能体的**独立更新可能偏离全局最优方向**。

异质SAC框架优势

- 通过**熵正则化**鼓励充分探索
- 异质策略网络适应不同动作空间
- 序贯更新机制解决信用分配
- 双Q学习减少价值过估计

核心思想：序贯更新使后更新智能体能够利用前序智能体的最新策略计算梯度，**保证个体优化与全局优化方向一致**。

3.3 怎么解决

多智能体软Q函数序列分解

软Bellman方程

软Q函数

$$Q_{\pi}^{\text{soft}}(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim \mathcal{T}} [V_{\pi}^{\text{soft}}(s')]$$

软值函数

$$V_{\pi}^{\text{soft}}(s) = \mathbb{E}_{a \sim \pi} \left[Q_{\pi}^{\text{soft}}(s, a) - \alpha \sum_{i=1}^n \log \pi_i(a_i | o_i) \right]$$

通过在Q值中减去策略对数概率的加权和来引入熵正则化，鼓励探索。

边缘化多智能体软Q函数

$$Q_{\pi}^{i_{1:m}}(s, a^{i_{1:m}}) \triangleq \mathbb{E}_{a^{-i_{1:m}} \sim \pi^{-i_{1:m}}} [Q_{\pi}^{\text{soft}}(s, a^{i_{1:m}}, a^{-i_{1:m}})]$$

通过对未选择动作的智能体的动作进行边缘化求期望，得到仅依赖于子集动作的价值函数。

评论家网络更新

损失函数

$$\mathcal{L}_Q(\varphi) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}} \left[(Q_{\varphi}(s, a) - y)^2 \right]$$

目标值

$$y = r + \gamma \left(\min_{k=1,2} Q_{\varphi'_k}(s', a') - \alpha \sum_{i=1}^n \log \pi_{\theta'}^i(a'^i | o'^i) \right)$$

采用双Q学习机制以减少价值过估计。

策略网络更新

$$J(\theta) = \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_{\theta}} [\alpha \log \pi_{\theta}(a | s) - Q_{\text{old}}(s, a)]$$

最小化该目标函数等价于最大化智能体的期望Q值并最大化其策略熵。

关键优势：顺序更新机制使得每个智能体在更新时能够考虑先前已更新智能体的策略变化，从而实现更有效的协调。

3.3 怎么解决

基于Plackett-Luce的序贯更新机制

序列选择器网络

$$\mathbf{o} = O_{\xi}(\mathbf{z}) \in \mathbb{R}^n$$

序列选择器 $\mathbf{o}_{\xi}$ 是一个独立的神经网络模块，其输入为从经验回放缓冲区采样的批次数据中提取的**频率响应特征**，输出为各智能体的优先级评分

Plackett-Luce模型

Plackett-Luce 模型提供从评分空间到排列分布的**可微映射**，支持端到端策略梯度优化。

$$P_{\xi}(\sigma|\mathbf{z}) = \prod_{k=1}^n \frac{\exp(o_{\sigma_k})}{\sum_{j=k}^n \exp(o_{\sigma_j})}$$

贪婪排序策略

在实际训练中，采用贪婪策略确定更新顺序：优先级评分最高的智能体首先更新策略网络，其次更新评分第二高的智能体，依此类推。

物理意义：序列选择器学习到的更新顺序反映了不同类型设备在频率调节中的动态响应特性——储能响应速度快优先更新，光伏调节能力受辐照度约束，同步机惯量大但响应较慢。




图3.3.3 序列选择器网络结构







图3.3.4 基于 Plackett-Luce 模型的序列采样机制

3.4 效果如何


实验设定

由 IEEE 13 节点配电网与 IEEE 9 节点输电网通过变压器耦合构成


配电网接入 7 个光伏系统与 3 个储能系统（共 10 个智能体），输电网包含 3 台同步发电机。光伏和储能的最大发电能力分别设置为 300 MW 和 240 MW，以模拟反向潮流场景。



(b) 采样曲线 1



(c) 采样曲线 2



(d) 采样曲线 3

图3.4.1 IEEE 13 节点配电网与 IEEE 9 节点输电网联合测试系统拓扑

图3.4.2 光伏数据采样曲线

3.4 效果如何

算例分析




图3.4.3 500 个训练回合中的学习曲线的平均回合奖励对比

与单智能体算法对比

多智能体方法（OHASAC、HASAC、HAPPO）相比单智能体算法（SAC、PPO）表现出**更高的数据利用效率和训练稳定性**。这是因为多智能体方法能够有效协调各设备之间的协同动作。OHASAC收敛最快奖励值最高。





图3.4.4 所提方法与不同配置的基准 HASAC 的训练曲线和惩罚项对比

3.4 效果如何

多场景性能验证

实验场景设计

线路开断故障

4号及6号节点在10s时刻断开关键线路，测试系统应对大扰动的能力。

负荷突增故障

6号节点在10s时刻增加40%负荷，测试系统的快速响应能力

正常运行

辐照度持续变化，测试系统在平稳运行下的控制性能。




图3.4.6 负荷突增故障下各算法频率偏差对比




图3.4.5 线路开断故障下各算法频率偏差对比




图3.4.7 正常状态下频率偏差对比

场景	算法	$ \Delta f _{\max}$	$ \Delta f _{\text{avg}}$
线路开断	SAC	0.217	0.093
	HASAC	0.186	0.076
	OHASAC	0.156	0.065
负荷突增	SAC	0.283	0.125
	HASAC	0.252	0.108
	OHASAC	0.201	0.089

结论： OHASAC在所有故障场景下**均取得最优或接近最优的性能**，验证了方法的鲁棒性和泛化能力。

3.4 效果如何

可变辐照度与大规模系统验证




图 3.4.8 辐照度持续上升的频率偏差




图 3.4.10 辐照度持续上升有功功率




图 3.4.12 IEEE 34 节点系统线路故障下频率偏差对比




图 3.4.9 光伏系统 PV671 的有功输出




图 3.4.11 储能系统在辐照度持续上升下动态有功

实验设置

- ✓ **可变辐照度**: OHASAC在辐照度持续变化的情况下保持稳定的控制性能。
- ✓ **光伏-储能协同**: 光伏与储能的动态配合有效平抑了频率波动。
- ✓ **可扩展性**: 在34节点大规模系统中仍保持优异性能

性能提升: OHASAC相比次优方法HASAC, 频率偏差峰值降低约**57%**, 频率恢复时间缩短约**30%**, 验证了异质动作空间序贯更新机制的有效性。

本章小结

1. 本章提出基于异质多智能体强化学习的 OHASAC 方法，用于解决主动配电网负荷频率支撑控制中离散与连续动作共存的动作空间异质性问题。
2. 构建输配协同动态模型，设计异质动作空间软演员-评论家框架，通过分策略网络与多智能体软 Q 函数分解实现精确信用分配。
3. 在 IEEE 3 机 9 节点系统多种扰动场景下验证，OHASAC 频率恢复更快、偏差更小，能有效处理混合动作空间策略优化。

04

第四章：异质资源协同下的主动 配电网充电负荷调度

4.1 问题是什么

异质资源协同的充电负荷调度问题

多充电站协同调度场景

在电动汽车充电网络中，不同充电站在**空间分布**、**容量配置**、**储能资源**、**用户结构**等方面存在多维异质性。

资源异质性表现

空间分布异质性

城区/郊区/高速服务区站点，充电需求时空分布差异显著

容量配置异质性

十桩级到百桩级不等，充电功率与容量差异显著

储能资源异质性

部分站点配置储能，容量从100kWh到1MWh不等

用户结构异质性

通勤/营运/过境车辆占比各异，充电时长与soc需求不同

核心难点：跨站点约束协同

各站点储能约束相互独立且容量不均衡，当某站点面临充电高峰但本地储能不足时，**缺乏从相邻站点借用储能容量的柔性机制**。

典型场景

高峰期站点A储能耗尽，站点B储能充裕但无法共享，导致站点A被迫从电网高价购电，站点B储能闲置。




图4.1 基于预测多站调度整体示意

💰 **经济目标：**最大化充电站运营利润 ⚡ **协作目标：**提高站间协作配合能力

🔋 **储能目标：**提高利用率，实现峰谷套利 🕒 **服务目标：**最小化用户等待时间

4.2 为什么难

现有充电站调度研究的核心差距

1 多站点间储能容量约束缺乏柔性共享机制

问题描述

现有方法普遍假设**站点储能独立运营**，缺乏从相邻站点借用储能容量的柔性机制，导致储能利用率低、运营成本高。

技术挑战

需要设计**跨站点储能共享机制**，在不改变物理拓扑的前提下实现储能容量的逻辑共享与协同调度。

2 交通流预测信息未能有效融入分布式调度决策

问题描述

先预测后优化的**两阶段策略**导致误差累积，预测误差会传递到调度决策中，降低控制性能。

技术挑战

需要设计**端到端的预测-调度联合优化框架**，将交通流预测信息直接融入强化学习决策过程。

3 Dec-POMDP框架下多站协同学习的约束满足与策略更新稳定性保障不足

问题描述

部分可观测环境下的多智能体强化学习面临**非平稳性和约束满足**的双重挑战。

技术挑战

需要设计**信赖域约束机制**保证策略更新的稳定性，同时满足储能SOC约束、功率约束等多重约束。

4.3 怎么解决

虚拟共享储能与影子价格机制




图4.3 多站点虚拟共享储能与交通感知模型架构

虚拟共享储能
逻辑合并储能容量

交通流预测
ASTGCN联合预测

影子价格机制
调控储能充放电

MARL调度
多智能体协同决策

虚拟共享储能建模

将各站点本地储能在**账务上虚拟合并**为一个能量库存，在**物理上各站仍独立运行**。

$$E^{\text{pool}} = \sum_{k=1}^N E^k$$

虚拟能量池总容量等于各站点储能容量之和。

影子价格机制

基于SoftPlus函数构造的影子价格：

$$\lambda_t = \frac{1}{k} \ln \left(1 + \exp \left(k \cdot \frac{E^{\text{pool}} - E_t^{\text{pool}}}{E^{\text{pool}}} \right) \right)$$

SOC低区与高区时影子价格上调，中部最低，激励储能充放电套利。


核心优势：虚拟共享机制在不改变物理拓扑的前提下，实现了储能容量的逻辑共享与协同调度，提高了整体储能利用率。

4.3 怎么解决

基于图卷积神经网络的交通流预测


ASTGCN模型架构

基于注意力时空图卷积网络的多站点交通流联合预测模型，整合**时间注意力**、**空间注意力**与**图卷积**三种机制。



时空特征编码



$$\mathcal{X} = \{\mathcal{X}^{(h)}, \mathcal{X}^{(d)}, \mathcal{X}^{(w)}\} \in \mathbb{R}^{3 \times T \times M \times F}$$



图卷积操作

$$\text{GCN}(X) = \sigma \left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} X W \right)$$

$$g_\theta * Gx = g_\theta(\mathbf{L})x = \sum_{k=0}^{K-1} \theta_k T_k(\tilde{\mathbf{L}})x$$



4.3 怎么解决

多智能体强化学习建模与VS-MATRPO算法




图4.3.2 多站协同调度系统框架流程图

局部观测向量

预测信息

未来时段的预测到达率与充电需求

运行状态

当前SOC、充电车辆数、等待车辆数

经济信息

实时电价、影子价格、分时电价

奖励函数设计

- 💰 利润组件: 充电收入 - 购电成本
- ⚡ 频率惩罚: 频率偏差惩罚项
- 📈 套利激励: 影子价格激励项

自适应信赖域调整

根据KL散度动态调整信赖域半径, 保证策略更新的稳定性。

4.4 效果如何

基准算法性能对比




图4.4.1 交通流预测结果




图4.4.2 多智能体强化学习算法平均奖励收敛曲线

算法性能对比

算法	平均奖励 10^2	收敛速度	稳定性
MAPPO	225.3	中	中
MAA2C	218.7	慢	低
本文算法	238.5	快	高

关键发现

- ★ **收敛性能：** MATRPO相较于MAPPO与MAA2C在收敛速度、稳定性与最终平均奖励收益等维度整体占优。
- ★ **信赖域机制：** 自适应信赖域调整机制有效保证了策略更新的稳定性，避免了训练过程中的性能崩溃。
- ★ **预测精度：** ASTGCN模型的预测精度优于LSTM、GRU等基线方法，为调度决策提供了可靠的前瞻信息。

4.4 效果如何

多站点协同调度效果




图4.4.3 充电价格与到达率




图4.4.4 需求电量变化




图4.4.5 充电与等待车辆数




图4.4.6 多站功率利用演化

模型可以控制**从储能单元和电网馈线中分别获取适当比例的能量**，并始终**未超过并网功率上限**。采取分时段动态定价，充电价格随到达率动态调整，**高峰时段提高价格抑制需求，低谷时段降低价格吸引用户**，实现供需平衡。

4.4 效果如何

储能协同调度




图4.4.5 三站储能功率




图4.4.6 三站储能功率




图4.4.7 三站储能功率




图4.4.8 影子价格与虚拟能量池平均 SOC 的日内演化

储能协同调度

高需求站点的本地储能进行**放电**、低需求站点则为本地储能**充电**的差异化调度策略，实现了储能资源的跨站点协同。

储能系统通过**低价时段充电、高价时段放电**实现峰谷套利，验证了影子价格机制对储能充放电行为的有效调控。

4.4 效果如何

影子价格调控




图4.4.7 站点0的SOC与充电定价




图4.4.8 站点1的SOC与充电定价





图4.4.9 站点2的SOC与充电定价






影子价格

通过影子价格因子影子价格与虚拟能量池平均SOC呈现**负相关关系**，SOC低时影子价格上调抑制放电，SOC高时影子价格下调鼓励放电。

4.4 效果如何

消融实验



结论：储能系统贡献约32.8%的利润提升，预测模块贡献约15.8%的利润提升，两者协同作用实现1+1>2的效果。

本章小结

1. 本章提出基于虚拟共享的多智能体强化学习算法VS-MATRPO，用于解决多电动汽车充电站因结构异质性带来的协同调度难题。
2. 构建交通-电力耦合三层调度模型，通过虚拟共享储能与影子价格实现跨站协同，并利用ASTGCN预测交通流量、结合排队论完成充电需求建模。
3. 将调度问题建模为分布式部分可观测马尔可夫决策过程，设计综合奖励函数与自适应信赖域约束，实验验证该方法能有效降低网损、抑制电压越限并提升资源利用效率。。

05

第五章：大语言模型 增强的强化学习框架

5.1 问题是什么

强化学习方法在电力系统应用中的两大瓶颈

1 仿真环境构建的高门槛

问题描述

构建符合工程标准的仿真脚本需要**深厚的领域知识与数周的专家工作量**，严重制约了MARL方法的推广应用。

技术挑战

需要理解电力系统物理模型、潮流计算、设备约束等专业
知识，并编写复杂的仿真代码。

现有方法局限

现有代码生成方法缺乏约束感知与质量保障机制，生成的
代码往往存在约束违反或数值稳定性问题。

2 预训练模型的泛化困境

问题描述

针对特定场景训练的策略在面对**分布偏移**时往往性能下降
，且神经网络的黑箱特性使得运行人员难以判断决策的可
靠性。

技术挑战

需要设计灵活的任务适配机制，使预训练模型能够根据当
前场景特征自适应调整决策策略。

现有方法局限

现有LLM-RL融合研究在电力系统应用中缺乏场景识别与混
合决策机制，无法实现LLM语义理解与RL优化决策的有效
协同。

研究目标：① 开发能够自动生成高质量仿真环境的APG框架；② 构建能够智能部署预训练模型的DeepVVC系统，实现LLM与RL的深度融合。

现有LLM-RL融合研究的核心差距

1 仿真环境自动构建缺乏约束感知与质量保障机制

问题描述

现有代码生成方法（如CodeT5、AlphaCode）专注于通用编程任务，缺乏对**电力系统物理约束**的感知能力。

技术挑战

需要设计**约束提取-多提供商生成-评估-优化**的闭环机制，确保生成代码满足电力系统约束。

2 预训练RL模型的在线部署缺少灵活的任务适配机制

问题描述

现有方法（如ReAct、Toolformer）将LLM作为推理引擎，但缺乏与**预训练RL模型**的有效协同机制。

技术挑战

需要设计**智能路由机制**，根据当前场景特征动态选择LLM、RL或混合决策模式。

3 LLM语义理解与RL优化决策的协同融合方法缺失

问题描述

LLM擅长**语义理解与知识推理**，RL擅长**数值优化与策略学习**，但两者的融合机制尚未建立。

技术挑战

需要设计**混合决策协调机制**，实现LLM的语义决策与RL的数值决策的有效融合。

5.3 怎么解决

LLM增强的马尔可夫博弈框架




图5.3 多场景自适应控制框架整体架构

与前述章节方法的关联:

- APG框架生成仿真环境 → 支持SHOM/OHASAC/MATRPO训练
- DeepVVC智能部署 → 实现预训练模型的跨场景适配

电力系统运行场景定义

场景特征

拓扑结构、负荷分布、新能源渗透率、约束条件等

场景异质性

不同场景下环境动力学、奖励函数、约束条件存在显著差异

LLM增强算子空间

- </> **环境生成算子:** 自动生成符合约束的仿真代码
- Q **场景识别算子:** 识别当前场景特征并选择适配策略
- ⚙️ **混合决策算子:** 协调LLM与RL的决策融合

核心思想: 将LLM作为增强算子嵌入MARL框架, 利用LLM的语义理解能力解决场景异质性问题

。

5.3 怎么解决

APG自主规划生成框架




图5.3 多场景自适应控制框架整体架构

APG 框架采用分层智能体架构，包含四个核心组件：

APG核心组件

约束提取模块

从自然语言描述中提取物理约束与数值约束

多提供商生成模块

多个LLM提供商并行生成候选代码

评估智能体

基于MARL的代码质量评估与排序

BNSE机制

基于贝叶斯优化的超参数优化

5.3 怎么解决

APG自主规划生成框架




图5.3 APG 框架工作流程示意图

BNSE (Best-of-N with Step Enhancement) 机制是 APG 框架的核心创新，通过系统的步骤分解、多维分析和智能融合来优化规划质量。BNSE 机制的执行过程可分为三个阶段。在候选规划选择阶段，从 N 个候选规划中选择得分最高的规划作为基础。





图5.3 APG 框架状态转换示意图

5.4 效果如何

APG框架实验验证

- 设计了10 个 N-1 故障仿真任务，每个任务需生成包含故障模拟、保护动作、负荷转供及系统恢复的完整 OpenDSS 脚本；
- 对比 6 种方法：Direct LLM（单一 LLM）、APG (Base)、APG (+CE)、APG (+MP)（加多提供商生成）、APG (+Eval)（加评估智能体）、APG (BNSE)（完整框架）；
- 依据 ElecBench 基准标准，从真实性、逻辑性、稳定性、表达性 4 个维度（评分 0–70 分）评估各方法性能。


方法		平均得分	约束满足率 (%)	可执行率 (%)	文档完整性 (%)
Base	(Direct LLM)	32.17	47.06	30.0	40.95
+CE		43.91	60.91	70.0	55.00
+MP		48.80	72.76	80.0	64.13
+Eval		56.00	79.61	60.0	74.86
+BNSE (Full)		60.26	85.70	80.0	84.71




任务	Direct LLM	APG (BNSE)	得分增益
任务 1: 线路 800-802 故障	53	65	+12
任务 2: 线路 808-810 故障	49	63	+14
任务 3: 线路 816-818 故障	54	65	+11
任务 4: 变压器故障	48	61	+13
任务 5: 母线 834 故障	50	64	+14
任务 6: 线路 854-856 故障	55	66	+11
任务 7: 多重故障场景	51	63	+12
任务 8: 联络线 814-850 切换	54	65	+11
任务 9: 分布式电源脱网	50	63	+13
任务 10: 负荷转供场景	54	65	+11
平均	51.8	64.0	+12.2

5.4 效果如何

APG框架实验验证



(a) 整体拓扑与故障/联络线路径



(b) 从正常到恢复的运行状态转换

图5.3 IEEE 34 节点网络任务 6 (线路 854-856 故障) 拓扑与状态演进示意图

以任务 6 (线路 854-856 故障) 为例, 展示了配电网拓扑与故障恢复过程的可视化。图 (a) 给出了 IEEE 34 节点配电网的整体拓扑结构, 该网络为典型的辐射状配电系统, 从变电站节点 800 出发经多条馈线向下游负荷供电。图中橙色区域标注了线路 854-856 故障的影响范围, 橙色虚线表示故障导致失电的线路; 绿色路径标注了可用于负荷转供的联络线 858-834, 通过闭合该联络线可从相邻馈线获取备用电源

5.4 效果如何

DeepVVC混合决策智能体

智能路由机制

根据场景特征动态选择决策模式：

场景识别
提取拓扑、负荷、新能源等特征

路由决策
基于场景特征选择最优决策模式

LLM-Only	若 $C_{task} < \tau_{LLM}$
RL-Only	若 $C_{task} > \tau_{RL} \wedge C_{model} > 0.6$
RL-Only	若 $C_{urgency} > 0.8 \wedge C_{model} > 0.7$
Adaptive	若 $\sigma_{state} > \tau_{\sigma} \wedge C_{model} > 0.5$
Hybrid-RL-First	若检测到优化类任务
Hybrid-LLM-First	若 $C_{task} > 0.5$
LLM-Only	其他情况

五种决策模式：

LLM-Only 纯LLM决策	RL-Only 纯RL决策
Hybrid-LLM-First LLM主导混合	Adaptive 自适应混合
Hybrid-RL-First RL主导混合	





图5. DeepVVC系统结构

5.4 效果如何

PowerZoo平台

PowerZoo 电力系统多智能体强化学习平台



1. 核心计算引擎：OpenDSS 内核物理仿真：基于 OpenDSS 实现配电网三相不平衡潮流计算。交互接口：通过 OpenDSSDirect 与 Python 实时交互，支持 APG 框架脚本自动加载。设备建模：精确模拟调压器、电容器、储能及分布式光伏的物理特性。

2. 标准化环境接口：符合 Gym 规范
任务建模：采用 Dec-POMDP 模型，实现电力系统状态量与动作空间的双向映射。异质协同：为每一类异质设备（如储能、逆变器）定义独立的局部观测与控制指令。奖励设计：灵活配置“电压越限-损耗-控制代价”的加权结构，确保控制的多目标优化。

3. 高性能算法库：创新与基线集成
算法体系：集成 SHOM、OHASAC、MATRPO 等本文创新算法，兼容 MAPPO、HAPPO 等主流基线。

本章小结

1. 本章构建 LLM 与 MARL 深度融合框架，重点解决 MARL 在工程应用中场景异质性带来的仿真构建复杂、跨场景迁移困难等问题。
2. 依次提出 LLM 增强马尔可夫博弈建模、APG 自主环境生成、DeepVVC 混合决策智能体架构，并搭建 PowerZoo 标准化强化学习平台。
3. 实验验证所提框架在约束满足率、跨场景成功率等指标上显著优于基准方法，证明其有效性、通用性与可扩展性。

06

第六章：总结与展望

本文的的主要贡献

1 SHOM方法

核心贡献

基于电压-无功灵敏度的动态排序与序贯更新机制，解决异质设备协同下的策略冲突问题。

2 OHASAC方法

核心贡献

基于Plackett-Luce排序模型的序贯更新机制，解决异质动作空间下的信用分配难题。

3 MATRPO方法

核心贡献

虚拟共享储能与影子价格机制，实现跨站点储能协同调度。

4 LLM-MARL框架

核心贡献

APG框架实现仿真环境自动构建，DeepVVC实现预训练模型的智能部署。

研究脉络：从**设备异质性**（SHOM）到**动作空间异质性**（OHASAC），再到**资源异质性**（MATRPO），最后上升到**场景异质性**（LLM-MARL），形成完整的异质协同控制理论体系。

未来研究方向

1 实际系统部署与硬件在环验证

研究内容

- 依托人在回路仿真平台评估算法在真实条件下的性能
- 选择典型配电网台区开展示范应用
- 验证算法在实际系统中的鲁棒性与可靠性

难点挑战

- 通信延迟与丢包对控制性能的影响
- 传感器噪声与量测误差的影响
- 实时性与计算资源的平衡

2 安全约束与可信决策保障

研究内容

- 引入安全强化学习技术增强技术可靠性
- 结合形式化方法进行离线安全性证明
- 设计基于安全屏障函数的在线安全滤波器

难点挑战

- 高维状态空间下的安全性验证
- 实时安全约束满足的计算效率
- 安全性与最优性的权衡

3 大模型与强化学习的深度融合

研究内容

- 利用LLM提取领域知识构建知识增强的状态表示
- 研究基于自然语言的人机交互界面
- 探索视觉语言模型的多模态决策框架

难点挑战

- LLM推理延迟与实时控制的矛盾
- 知识提取的准确性与完备性
- 多模态信息的有效融合



博士期间取得成果

代表性文章

1. **Zheng XD**, Yu SX, Cao H, et al. Sensitivity-Based Heterogeneous Ordered Multi-Agent Reinforcement Learning for Distributed Volt-Var Control in Active Distribution Network[J]. IEEE Transactions on Smart Grid, 2025, 16(3): 2115-2126. [SCI, IF=9.8]
2. **Zheng XD**, Xue SS, Cao H. Weighted-Sign Based Sequential Synchronization Control via Residual Reinforcement Learning[J]. The International Journal of Intelligent Control and Systems 2025,30(4): 336-342. [卓越计划]
3. **郑晓东**, 等. 耦合交通预测多智能体强化学习的虚拟聚合储能多充电站协同调度[J]. 电网技术, 2026, 50(5): 1973-1984 [中文EI]
4. **Zheng XD**, et al. Agentic Planning for Power System Simulation Task Orchestrations Based on Multi-Agent Systems[C]. 2025 8th International Conference on Robotics, Control and Automation Engineering (RCAE), 2025: 576-584.
5. **Zheng XD**, et al. Graph-oriented deep reinforcement learning approach for vehicle routing problems[J]. Neurocomputing, 2026, 699: 134376.
6. **Zheng XD**, Wang T, Xue SS, et al. Two-Stage Flocking Formation Control Based on Constrained Boundary[C]. 5th Chinese Conference on Swarm Intelligence and Cooperative Control (CCSICC). Shenzhen: Springer, 2023: 1112-1122.
7. **Zheng X**, Xue S, Cao H, Wang F, Zhang M. A Cost-efficient Smart IoT Device Controlling System Based on Bluetooth Mesh and Cloud Computing[C]. 2020 Chinese Automation Congress (CAC). 2020: 3374-3379.

专利：

- [1] **郑晓东**, 曹晖, 石天卓, 等. 一种基于约束异构有序多智能体强化学习的电压无功控制方法. 2025-11-25 (ZL202411439608.4)
- [2] 薛霜思, **郑晓东**, 郭子航, 等. 基于固定时间快速终端滑模和比例积分的机械臂控制方法. 2024-2 (ZL202410464369.8)
- [3] 曹晖, **郑晓东**, 薛霜思等. 一种基于高压细水雾的变电站智能机器人消防系统及方法. 2023-03-21 (ZL202210464097.6)
- [4] 曹晖, 石天卓, **郑晓东**, 一种基于深度学习的交通流量和充电站负荷预测方法. 2023-11-07 (ZL202411579602.7)
- [5] 曹晖, 薛霜思, **郑晓东**, 等. 基于改进人工势场法的多智能体主从式编队控制方法. 2022-10-28 (ZL202110549561.7)

致谢

感谢曹晖老师的悉心指导

感谢课题组同门的帮助与支持

感谢各位评审专家的宝贵意见

恳请各位老师批评指正